

# Reporte Técnico de Sustentación: Proyecto LiT / OpenCLIP

---

## 1. Paper, modelo o línea temática asignada

- **Línea Temática:** Aprendizaje Contrastivo Multimodal y Arquitecturas bi encoder.
  - **Paradigma Principal:**
    - \*\* Zhai, X., Wang, X., Mustafa, B., Steiner, A., Keysers, D., Kolesnikov, A., & Beyer, L. (2022). LiT: Zero-Shot Transfer with Locked-image text Tuning. CVPR 2022.
    - \*\* Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision. Proceedings of the 38th International Conference on Machine Learning (ICML 2021).
    - \*\* Ilharco, G., Wortsman, M., Wightman, R., Gordon, C., Carlini, N., Taori, R., ... Schmidt, L. (2021). OpenCLIP: Open-Source CLIP Models. arXiv preprint arXiv:2104.02057
  - **Modelos Evaluados:** \* Encoders Visuales (Anclas): **ResNet18** y **Vision Transformer (ViT-B-16)**.
    - Encoders de Lenguaje (Ajustados): **BERT-tiny**, **DistilBERT** (arquitecturas tipo Encoder) y **GPT-2** (arquitectura tipo Decoder adaptada de forma causal).
- 

## 2. URL del repositorio entregado

- **Repositorio Local del Proyecto:** `./proyectoRetrieval` (pesos del modelo, tokenizadores serializados y configuraciones exportadas mediante comandos del sistema como `!cp -r ./data ./proyectoRetrieval`).

Además en la raíz se encuentra el cuaderno de experimento.

---

## 3. Cuadernos usados

El desarrollo y la formulación del problema se basan en la secuencia avanzada del curso **MCC225**:

- **Cuaderno 6:** Conceptos de alineamiento multimodal, bi-encoders contrastivos independientes y minado de ejemplos negativos.
  - **Cuaderno 9 y 10:** Configuración de entornos OpenCLIP, uso de checkpoints fundacionales a gran escala (**ViT-B-32** con pesos de LAION y OpenAI) y métricas estandarizadas de evaluación en recuperación cruzada.
- 

## 4. Notebook, script o archivo ejecutado

- **Archivo de Exposición Principal:** `LopezFloresRoyer_ExperimentacionCuadernoLiT.ipynb` es el cuaderno de la experimentación.
- **proyectoRetrieval** Mini aplicación de recuperación texto imagen usando el modelo entrenado
- **Dataset de Trabajo:** Subconjunto estructurado basado en **Flickr8k** (`jxie/flickr8k`), particionado en un entorno de desarrollo controlado (400 muestras de entrenamiento, 100 de validación y 100 de

prueba).

---

## 5. Celda, función o bloque de código clave

El núcleo operativo del proyecto se divide en tres estructuras algorítmicas esenciales:

### 1. El Bloqueo de Gradientes y la Pérdida Contrastiva (**LiTModel** e **infonce\_loss**):

```
class LiTModel(nn.Module):
    def __init__(self, image_model, text_model, temperature=0.07):
        super().__init__()
        self.image_model = image_model
        self.text_model = text_model
        self.logit_scale = nn.Parameter(torch.ones(1) * np.log(1 / temperature))

        # Mecanismo mandatorio del Paper: Congelar pesos de la imagen
        for param in self.image_model.parameters():
            param.requires_grad = False

    def forward(self, images, input_ids, attention_mask):
        with torch.no_grad(): # Garantiza que no fluyan gradientes por la rama
visual
            image_features = self.image_model(images)
            text_features = self.text_model(input_ids, attention_mask)

            logit_scale = self.logit_scale.exp()
            logits_per_image = logit_scale * image_features @ text_features.t()
            logits_per_text = logits_per_image.t()
            return logits_per_image, logits_per_text

    def infonce_loss(logits_per_image, logits_per_text):
        labels = torch.arange(logits_per_image.shape[0],
device=logits_per_image.device)
        loss_i = F.cross_entropy(logits_per_image, labels)
        loss_t = F.cross_entropy(logits_per_text, labels)
        return (loss_i + loss_t) / 2
```

---

## 7. Componentes del Pipeline

### La Exploración del Espacio de Hiperparámetros (Grid Search)

Bucle iterativo que evalúa las combinaciones de `image_models`  $\times$  `text_models`  $\times$  `temperaturas` ( $\tau$ ), registrando las métricas del *test set* en un `DataFrame` histórico para aislar la mejor configuración.

### La Indexación de Alta Velocidad (FAISS Indexing)

Sección donde los embeddings normalizados son transferidos a estructuras de tipo `faiss.IndexFlatL2(d)`, convirtiendo la similitud matemática en una consulta operativa persistente (`faiss.write_index`).

## 8. Resultados Obtenidos

- **Alineamiento Exitoso:** Se logró extraer y consolidar un modelo optimizado apto para tareas de búsqueda cruzada en e-commerce y recuperación de información.
- **Geometría Semántica Distinguida:** En la prueba de diagnóstico tripartita, el modelo local demostró un comportamiento altamente selectivo y limpio, reduciendo la inter-similitud entre conceptos cruzados no relacionados.
- **Persistencia del Pipeline:** Los componentes críticos del sistema (pesos de la torre lingüística ajustada, el tokenizador y el índice de vectores) quedaron guardados físicamente en disco (`./data/`).

## 9. Métricas y Evidencia Utilizada

Para sustentar las conclusiones científicas del proyecto se utilizaron tres fuentes de evidencia:

1. **Métricas de Ranking (Recall@K):** Probabilidad de encontrar el *match* correcto en los primeros resultados ( $R@1$ ,  $R@5$ ,  $R@10$ ), calculada en la función `evaluate_model()`.
2. **Gráfico de Inferencia Cualitativa:** Visualización generada por `plt.subplot()` que renderiza en orden secuencial el Top- $k$  de imágenes recuperadas ante consultas en lenguaje natural (ej. "A dog running through the grass").
3. **Tabla Comparativa de Diagnóstico de Ortogonalidad:** Evaluaciones de la inter-similitud promedio en conceptos cruzados:

| Modelo               | Inter-similitud Promedio | Estado del Espacio Semántico                       |
|----------------------|--------------------------|----------------------------------------------------|
| OpenAI CLIP original | 0.6689                   | Espacio denso, propenso a colapso de cono textual. |
| OpenCLIP LAION       | 0.4006                   | Espacio moderadamente disperso.                    |
| Tu Modelo LiT Local  | −0.0192                  | Espacio altamente ortogonal y disperso (Óptimo).   |

## 10. Cambios sobre el Cuaderno Original

- **Estrategia Asimétrica de Gradientes:** En contraste con el enfoque estándar del Cuaderno 6 (donde ambas torres se actualizan), se forzó la inmutabilidad de la rama visual mediante `requires_grad = False`.
- **Inclusión de Modelos Autoregresivos (Decoders):** Se diseñó e integró la clase `TextDecoderModel` para procesar texto usando GPT-2, adaptando la lectura de embeddings al último token válido basándose en la máscara de atención:

$$\text{sequence\_lengths} = \text{attention\_mask.sum(dim=1)} - 1$$

- **Automatización del Espacio de Búsqueda:** Se reemplazaron los entrenamientos fijos por un pipeline automático de *Grid Search* para probar de forma sistemática el impacto del hiperparámetro de temperatura en la función de pérdida InfoNCE.

## 11. Limitaciones Encontradas

⚠ **Restricción de Escala (Data Constraint):** Debido a los límites de hardware del entorno de desarrollo, el entrenamiento y testeo se acotaron a un subconjunto reducido (400 y 100 muestras respectivamente). Esto genera un sesgo de subrepresentación frente a los datasets completos de *Flickr30k* analizados en los cuadernos 9 y 10.

- **Riesgo de Sobreajuste Local:** La drástica reducción de la inter-similitud promedio ( $-0.0192$ ) indica que el modelo es sumamente eficiente separando los pocos conceptos presentes en el conjunto de test local, pero no se puede asegurar estadísticamente que mantenga la misma tasa de generalización ante un *pool* de millones de imágenes en producción.

---

## 12. Mejoras Propuestas

- **Migración a Scripts Modulares:** Transformar las celdas del *notebook* en un pipeline de producción reproducible mediante archivos `.py` independientes (ej. `src/models.py`, `src/train.py`) parametrizados con `argparse` o archivos de configuración `YAML`.
- **Minado Avanzado de Negativos:** Reemplazar los negativos aleatorios implícitos del *batch* por una estrategia de minado de negativos difíciles (*Hard Negative Mining*) usando distancias léxicas (TF-IDF) o vecindarios vectoriales previos en la función de pérdida, emulando la rigurosidad metodológica implementada en el Cuaderno 6.
- **Registro Automatizado de Experimentos:** Incorporar herramientas de tracking de artefactos (como **MLflow** o **Weights & Biases**) junto con un contenedor **Docker** formal para registrar de forma auditable el consumo de VRAM y el tiempo de reloj por cada iteración del *Grid Search*.