


OPEN CLIP/ LiT

Generando un retrieval



Lopez Flores Royer Amed
Cuadernos asignados: 6, 9 y 10




Problema, motivación y modalidades.

Crear un agente de recuperación multimodal para e-commerce, pero entrenar un modelo dual (como CLIP/OpenCLIP) desde cero requiere recursos computacionales masivos. Además, hacer *fine-tuning* de ambos encoders en un dataset pequeño destruye representaciones ricas previas (olvido catastrófico).

Buscando que combinación de modelos es mejor CNN, transformers, Bert o GPT-2.


La solución es el uso de LiT (**Bi-encoder contrastivo**), congelar el encoder de imagen y entrenar el modelo de texto

Modalidad: Imagen y Texto,






Arquitectura (LiT Bi-Encoder)



Solo vamos a entrenar el text encoder.





Entrenamiento, pérdidas y datos.

Pérdida de Imagen a Texto (Image-to-Text Loss):

$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(I_i, T_i)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(I_i, T_j)/\tau)}$$

Pérdida de Texto a Imagen (Text-to-Image Loss):


$$\mathcal{L}_{T \rightarrow I} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(T_i, I_i)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(T_j, I_i)/\tau)}$$

Pérdida Total:


$$\mathcal{L}_{\text{total}} = \frac{\mathcal{L}_{I \rightarrow T} + \mathcal{L}_{T \rightarrow I}}{2}$$

Pérdida

Función de pérdida



Flickr8k



Grid Search

CNN(Resnet) vs Transformer(ViT)

BERT tiny vs DistilBERT vs GPT-2

Temperatura: 0.07 vs 0.05



Métricas y resultados

	Modelo_Imagen	Modelo_Texto	Tipo_Texto	Tau	Loss_Test	R@1	R@5	R@10
0	CNN	prajjwal1/bert-tiny	encoder	0.07	2.106487	0.05	0.19	0.36
1	CNN	prajjwal1/bert-tiny	encoder	0.50	2.420011	0.06	0.22	0.33
2	CNN	distilbert-base-uncased	encoder	0.07	1.596721	0.14	0.49	0.66
3	CNN	distilbert-base-uncased	encoder	0.50	2.273955	0.21	0.50	0.66
4	CNN	gpt2	decoder	0.07	1.672738	0.17	0.41	0.61
5	CNN	gpt2	decoder	0.50	2.353040	0.05	0.27	0.41
6	Transformer	prajjwal1/bert-tiny	encoder	0.07	2.252259	0.02	0.20	0.31
7	Transformer	prajjwal1/bert-tiny	encoder	0.50	2.473358	0.02	0.15	0.25
8	Transformer	distilbert-base-uncased	encoder	0.07	1.506517	0.12	0.43	0.59
9	Transformer	distilbert-base-uncased	encoder	0.50	2.257400	0.09	0.36	0.52
10	Transformer	gpt2	decoder	0.07	1.960063	0.09	0.36	0.53
11	Transformer	gpt2	decoder	0.50	2.323819	0.11	0.32	0.44


Grid Search

Modelo_Imagen	CNN
Modelo_Texto	distilbert-base-uncased
Tipo_Texto	encoder
Tau	0.5
Loss_Test	2.273955
R@1	0.21
R@5	0.5
R@10	0.66

Mejor modelo



Relación de cuadernos.

Cuaderno 6	Cuaderno 9	Cuaderno 10
BI ENCODERS CONTRASTIVOS.  <pre>graph BT; S1[Sentence A] --> B1[BERT]; B1 --> P1[pooling]; P1 --> V1["Sentence A vec
[0.11, 0.74...]"]; S2[Sentence B] --> B2[BERT]; B2 --> P2[pooling]; P2 --> V2["Sentence B vec
[0.65, 0.42...]"]; V1 --> CS[Cosine-Similarity]; V2 --> CS; subgraph Bi-Encoder; CS; end</pre>	Muestra la extracción de embeddings, además nos muestra los negativos difíciles(la descripción comparte el contexto visual de la imagen), además del uso de LiT sobre OpenCLIP por los recursos.	Conexión de las representaciones finales a una base de datos vectoriales(FAISS), principalmente lo usaremos para el retrieval top k



Evidencia Reproducible (Implementación FAISS)

```
Consulta: 'A dog running through the grass'
=====

TOP 5 TEXTOS MÁS SIMILARES:
1. [Index 18]: A big dog chases a little dog on the grass .
2. [Index 16]: A dog with a Frisbee in front of a brown dog .
3. [Index 34]: A brown dog walks in the under brush .
4. [Index 69]: a black and white dog is wearing a red collar whilst walking on the grass .
5. [Index 5]: A brown dog running

MOSTRANDO TOP 5 IMÁGENES...
```

Top 1 (Idx: 53)



Top 2 (Idx: 32)



Top 3 (Idx: 52)



Top 4 (Idx: 42)



Top 5 (Idx: 86)



Se genero el vector embedding tanto para imágenes como texto, y según la consulta se extrae el texto como la imagen similar, además de la creación



Relación con las Actividades del Curso

Actividad 1	Actividad 2	Actividad 3
El agente de e-commerce requiere escalabilidad. LiT y FAISS juntos resuelven el problema de buscar un producto a partir de una descripción esto puede ser usado como un tool, además que definimos las métricas como R@k.	Replicamos el matching Imagen-Texto usando el dataset de Flickr8k, demostrando el uso de <i>embeddings</i> sobre un catálogo visual	Evolucionamos el pipeline. Pasamos del emparejamiento básico a un aprendizaje contrastivo complejo (InfoNCE) apoyado en el manejo de negativos difíciles para mejorar las fronteras de decisión semántica




Limitaciones

Limitaciones: La torre de imagen no aprende. Si el e-commerce tiene productos visualmente extraños que el modelo preentrenado no comprende, la torre de texto no podrá compensarlo por completo, además que los modelos contrastivos sin LiT son casi imposibles de entrenar. Hablando de modelos fundacionales como CLIP.



Pregunta Crítica

•Si nos enfrentamos a un "domain shift" masivo (ej. radiografías médicas o componentes electrónicos microscópicos), ¿hasta qué punto es sostenible mantener la torre de imagen bloqueada en lugar de asumir el costo de reentrenarla?




GRACIAS

Anexos. Una vista dinámica al infoNCE, variación por temperatura.



0.07

Usado en el paper



0.5

Usado en la experimentación



1.00

Casi no hay
diferencias entre
pares

Anexos.(Desarrollo de un retrieval text-image)


```
ExpoParcial docker compose up
[+] Running 1/1
  ✓ Container retrieval-api Created
Attaching to retrieval-api
retrieval-api | INFO: Started server process [1]
retrieval-api | INFO: Waiting for application startup.
Loading weights: 100%|██████████| 100/100 [00:00<00:00, 2523.71it/s]
retrieval-api | [transformers] DistilBertModel LOAD REPORT from: distilbert-base-uncased
retrieval-api | Key | Status |
retrieval-api | -----+-----+
retrieval-api | vocab_transform.bias | UNEXPECTED |
retrieval-api | vocab_layer_norm.bias | UNEXPECTED |
retrieval-api | vocab_layer_norm.weight | UNEXPECTED |
retrieval-api | vocab_projector.bias | UNEXPECTED |
retrieval-api | vocab_transform.weight | UNEXPECTED |
retrieval-api | Notes:
retrieval-api | - UNEXPECTED: can be ignored when loading from different task/architecture; not ok if you expect
retrieval-api | Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable
retrieval-api | INFO: Application startup complete.
retrieval-api | INFO: Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
retrieval-api | INFO: 172.21.0.1:57850 - "GET /static HTTP/1.1" 307 Temporary Redirect
retrieval-api | INFO: 172.21.0.1:57850 - "GET /static/ HTTP/1.1" 404 Not Found
retrieval-api | INFO: 172.21.0.1:57850 - "GET /favicon.ico HTTP/1.1" 404 Not Found
retrieval-api | INFO: 172.21.0.1:57862 - "GET /static HTTP/1.1" 307 Temporary Redirect
retrieval-api | INFO: 172.21.0.1:57862 - "GET /static/ HTTP/1.1" 404 Not Found
retrieval-api | INFO: 172.21.0.1:57862 - "GET /static HTTP/1.1" 307 Temporary Redirect
retrieval-api | INFO: 172.21.0.1:57862 - "GET /static/ HTTP/1.1" 404 Not Found
retrieval-api | INFO: 172.21.0.1:59694 - "GET /static/index.html HTTP/1.1" 200 OK
retrieval-api | INFO: 172.21.0.1:59694 - "GET /favicon.ico HTTP/1.1" 404 Not Found
retrieval-api | INFO: 172.21.0.1:39542 - "GET /static/index.html HTTP/1.1" 200 OK
retrieval-api | INFO: 172.21.0.1:39542 - "POST /api/retrieve HTTP/1.1" 200 OK
```

Uso de Docker compose para desplegar una mini app para obtener las imágenes y textos mas cercanos dada una descripción


<http://localhost:8000/static/index.html>



Consulta textual



Textos cercanos



Imágenes cercanas