

Ficha Técnica: Primera Exposición Académica

Estudiante: Royer Amed López Flores **Curso:** MCC225A - IA Generativa y Aprendizaje Multimodal **Cuadernos Asignados:** C6, C9, C10

1. Referencia completa del paper/modelo

- Zhai, X., Wang, X., Mustafa, B., Steiner, A., Keysers, D., Kolesnikov, A., & Beyer, L. (2022). LiT: Zero-Shot Transfer with Locked-image text Tuning. CVPR 2022.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision. Proceedings of the 38th International Conference on Machine Learning (ICML 2021).
- Ilharco, G., Wortsman, M., Wightman, R., Gordon, C., Carlini, N., Taori, R., ... Schmidt, L. (2021). OpenCLIP: Open-Source CLIP Models. arXiv preprint arXiv:2104.02057.
- Se usaron los cuadernos 6, 9 y 10.

2. Problema que aborda y motivación

Entrenar modelos *Dual Encoders* masivos (como CLIP) desde cero requiere cantidades exorbitantes de datos y cómputo. Por otro lado, el fine-tuning tradicional tiende a destruir las representaciones generalistas previamente aprendidas (olvido catastrófico). LiT resuelve esto enseñando a un modelo de texto a alinearse con las representaciones visuales fuertes de un modelo de imagen preentrenado (como los de OpenCLIP) sin alterar los pesos de este último, también en la experimentación veremos como influye la temperatura del infoNCE.

Además nuestro objetivo será crear una miniaplicación de retrieval de imagen-texto dado un texto.

3. Modalidades involucradas

Imagen y Texto (Búsqueda semántica cruzada y clasificación zero-shot).

4. Arquitectura

Dual encoder (Contrastive bi-encoder) asimétrico. Consiste en un **Image Encoder "Locked"** (pesos congelados, sin cálculo de gradientes) y un **Text Encoder "Unlocked"** (se entrena para proyectarse en el espacio del modelo visual).

5. Objetivo de entrenamiento o función de pérdida

Pérdida contrastiva (InfoNCE) aplicada sobre los embeddings normalizados, maximizando la similitud coseno de pares correctos y minimizando la de incorrectos dentro del batch. Además se está usando R@k para determinar que tan bueno es el modelo para encontrar los pares correctos.

- **Pérdida Contrastiva InfoNCE:** Se utiliza una pérdida simétrica bidireccional (Imagen-a-Texto y Texto-a-Imagen) parametrizada por un escalar de temperatura (τ).
- **Pérdida de Imagen a Texto (Image-to-Text Loss):**
$$\mathcal{L}_{I \rightarrow T} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(I_i, T_i) / \tau)}{\sum_{j=1}^N \exp(\text{sim}(I_i, T_j) / \tau)}$$

- **Pérdida de Texto a Imagen (Text-to-Image Loss):**
$$\mathcal{L}\{T \rightarrow I\} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(T_i, I_i) / \tau)}{\sum_{j=1}^N \exp(\text{sim}(T_j, I_i) / \tau)}$$
- **Pérdida Total:**
$$\mathcal{L}\{\text{total}\} = \frac{\mathcal{L}\{I \rightarrow T\} + \mathcal{L}\{T \rightarrow I\}}{2}$$
- **R@k:**
$$R@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(\text{rank}_i \leq k)$$

$$\mathbb{I}(\text{rank}_i \leq k) = 1 \text{ si } \text{rank}_i \leq k; 0 \text{ si } \text{rank}_i > k$$

6. Dataset(s) y protocolo experimental

El paper utiliza CC12M, YFCC100m, entre otros. El protocolo bloquea el backbone visual y entrena solo la torre de texto, lo que ahorra memoria y permite usar batches gigantes (hasta 32k en este tipo de batch tengo limitaciones de hardware por lo que se optó directamente a usar LiT). En nuestra experimentación, usamos el conjunto Flickr30k de los cuadernos. Entonces para la experimentación tenemos:

- **Dataset:** Flickr8k (subconjunto utilizado para agilizar la validación del *pipeline*).
- **Protocolo:** Se realizó un *Grid Search* evaluando arquitecturas visuales (CNN vs Transformer), textuales (BERT-tiny, DistilBERT, GPT-2) y temperaturas (0.07 vs 0.50). El mejor modelo se exportó a una base de datos vectorial mediante FAISS para realizar consultas de inferencia.

7. Métricas principales

- Loss de Test (InfoNCE).
- Retrieval Image-to-Text y Text-to-Image evaluado mediante **Recall@1, Recall@5 y Recall@10**.

8. Relación con los Actividades 1, 2 y 3

- **Actividad 1:** El objetivo final es construir un agente de consultas de *e-commerce* que recupere el mejor producto dada una imagen o texto. LiT se alinea perfectamente al usar recuperación (*retrieval*) y evaluar el éxito con Recall@K.
- **Actividad 2:** La tarea micro es el emparejamiento imagen-texto (Image-Text Matching). Empleamos Flickr8k para generar *embeddings* en un espacio semántico compartido, calculando la matriz de similitud y métricas R@K.
- **Actividad 3:** Pasamos de intentar una fusión profunda (*deep fusion*) costosa, hacia un alineamiento contrastivo más eficiente y elegante mediante un bi-encoder. Se integran además conceptos como el contraste con negativos aleatorios y semi-difíciles para forzar al modelo a aprender fronteras semánticas más finas.

9. Limitaciones, supuestos y costo computacional

- **Limitaciones:** Al congelar el encoder visual, se asume que las representaciones visuales preentrenadas son suficientes para el dominio objetivo. Si los productos del e-commerce tienen características visuales anómalas (fuera del dominio de preentrenamiento del CNN/ViT), el modelo text-only no podrá compensarlo. Además se ha visto overfitting en nuestro experimento pasando las 8 épocas.
- **Costo:** Notablemente menor que OpenCLIP clásico. Al no calcular gradientes en la torre visual, se ahorra memoria VRAM y tiempo de cómputo.

10. Pregunta crítica para la discusión oral

- ¿Hasta qué punto la estrategia LiT es resiliente a un "domain shift" severo? Es decir, si nuestro e-commerce vende productos industriales muy específicos que el encoder visual preentrenado nunca ha visto, ¿sigue siendo preferible bloquear la torre de imagen o deberíamos usar un fine-tuning completo como en OpenCLIP tradicional?

11. Matriz obligatoria de relación con cuadernos

Cuaderno	Idea técnica central	Relación con mi paper/modelo (LiT)	Limitación o pregunta crítica
C6	Bi-encoders contrastivos, embeddings compartidos, negativos difíciles y recuperación multimodal.	LiT utiliza exactamente esta arquitectura bi-encoder y la misma formulación de alineamiento. Evaluamos recuperación usando la matriz de similitud.	¿Es suficiente el entrenamiento con negativos aleatorios si el encoder visual está bloqueado?
C9	OpenCLIP como baseline contrastivo; extracción de embeddings y recuperación cruzada.	LiT es una evolución eficiente de la metodología de OpenCLIP, sustituyendo el co-entrenamiento por un ajuste guiado solo por texto.	¿Qué tanto perdemos en precisión al no usar el preentrenamiento nativo de imagen-texto de LAION?
C10	Text-to-image/Image-to-text retrieval, zero-shot, y búsqueda semántica indexada con FAISS.	Tras encontrar el mejor modelo LiT en nuestro <i>grid search</i> , replicamos este cuaderno integrando las representaciones a FAISS para <i>retrieval</i> rápido.	En un entorno de e-commerce real con millones de productos, ¿cómo escalar el índice FAISS manteniendo baja latencia?